Modelo do Trabalho de Conclusão de Curso da Faculdade de Computação (FACOM)

Cassio Lima Silva



Universidade Federal de Uberlândia
Faculdade de Computação
Bacharelado em Ciência da Computação

Uberlândia - MG
2026

Cassio Lima Silva

Modelo do Trabalho de Conclusão de Curso da Faculdade de Computação (FACOM)

Trabalho de Conclusão de Curso apresentado à Faculdade de Computação da Universidade Federal de Uberlândia, Minas Gerais, como requisito exigido parcial à obtenção do Título de Bacharel em Ciência da Computação

Área de concentração: Ciência da Computação

Orientador: Rodrigo Sanches Miani

Uberlândia - MG
2026

Dedico este trabalho à minha família e aos meus amigos, que foram meu alicerce e minha maior motivação durante todos os anos desta graduação.

Agradecimentos

Agradeço primeiramente aos meus pais e a toda a minha família, que representam a base fundamental da minha vida. Todo o amor, compreensão e suporte incondicional que recebi foram essenciais para que eu mantivesse o foco e a determinação, especialmente nos momentos de dúvida e cansaço. Este trabalho é, sem dúvida, o reflexo dos sacrifícios que fizeram por mim e da confiança inabalável que sempre demonstraram nos meus sonhos.

Ao meu orientador, Prof. Dr. Rodrigo Sanches Miani, expresso minha mais profunda gratidão. Muito obrigado pela paciência inesgotável, pelas valiosas orientações e por todo o tempo dedicado a acompanhar cada etapa do desenvolvimento deste projeto. O seu rigor científico, entusiasmo e os seus ensinamentos foram determinantes não apenas para a conclusão desta pesquisa, mas para o meu amadurecimento intelectual e profissional.

À Universidade Federal de Uberlândia (UFU) e, de maneira muito especial, à Faculdade de Computação (FACOM), por me proporcionarem um ambiente de excelência. Estendo meus sinceros agradecimentos a todos os professores e funcionários que, ao longo de todos estes anos de curso, contribuíram ativamente para a minha formação técnica, cidadã e humana, reafirmando diariamente a importância e a força do ensino superior público, gratuito e de qualidade.

Aos membros da banca examinadora, agradeço por terem aceitado o convite para avaliar este trabalho. As críticas, sugestões e contribuições enriquecedoras de vocês são passos fundamentais para o aprimoramento contínuo desta e de futuras pesquisas.

Aos meus amigos e colegas de curso, verdadeiros companheiros desta jornada. Sou imensamente grato pelas incontáveis horas de estudo compartilhadas, pelos debates construtivos, pelas noites em claro buscando soluções e, sobretudo, por tornarem a carga dos dias difíceis muito mais leve e as vitórias muito mais alegres. Vocês fizeram a diferença.

Por fim, a todos que, de maneira direta ou indireta, me apoiaram, me inspiraram e fizeram parte da construção deste longo caminho até a graduação. A conclusão deste ciclo também pertence a vocês. O meu muito obrigado.

O que observamos não é a natureza em si,
mas a natureza exposta ao nosso método de questionamento.
(Werner Heisenberg)

Resumo

A crescente incidência de desastres naturais demanda sistemas eficazes de monitoramento e resposta no gerenciamento de crises. Embora a Internet das Coisas (IoT) combinada à Inteligência Artificial seja promissora para a predição de situações críticas, a obtenção de dados reais sobre falhas de infraestrutura durante catástrofes é custosa, operacionalmente complexa e de difícil reprodução, dificultando o treinamento de modelos preditivos. Neste contexto, este trabalho tem como objetivo desenvolver um estudo experimental utilizando o simulador *IoTEventSim* para modelar e gerar cenários de desastre em ecossistemas IoT estruturados em *cloud-fog-edge*. O intuito é produzir conjuntos de dados rotulados e avaliar algoritmos de Aprendizado de Máquina na predição de estados críticos. A metodologia consiste na injeção de eventos dinâmicos que emulam falhas de rede e consumo de bateria nas fases normal, pré-desastre, desastre e pós-desastre. Os dados sintéticos extraídos passam por um *pipeline* de pré-processamento e treinam classificadores supervisionados. A avaliação do desempenho é realizada por meio de matrizes de confusão e métricas como acurácia, precisão, revocação e *F1-score*. Como resultado esperado, busca-se demonstrar quantitativamente que a integração de métricas da infraestrutura (rede e bateria) com dados de sensores otimiza a classificação das fases do desastre. Com este estudo, espera-se demonstrar que a simulação aliada ao aprendizado de máquina constitui uma abordagem promissora para mitigar a escassez de *datasets* reais com falhas sistêmicas, fornecendo subsídios para o desenvolvimento de ambientes resilientes de predição e mitigação de riscos.

Palavras-chave: Internet das Coisas. Aprendizado de Máquina. Simulação de Eventos. Previsão de Desastres. IoTEventSim.

Abstract

The increasing incidence of natural disasters demands effective monitoring and response systems in crisis management. Although the Internet of Things (IoT) combined with Artificial Intelligence shows promise for predicting critical situations, obtaining real data on infrastructure failures during catastrophes is costly, operationally complex, and difficult to reproduce, hindering the training of predictive models. In this context, this work aims to develop an experimental study using the *IoTEventSim* simulator to model and generate disaster scenarios in *cloud-fog-edge* IoT ecosystems. The goal is to produce labeled datasets and evaluate Machine Learning algorithms in predicting critical states. The methodology consists of injecting dynamic events that emulate network failures and battery consumption during normal, pre-disaster, disaster, and post-disaster phases. The extracted synthetic data go through a preprocessing *pipeline* to train supervised classifiers. Performance evaluation is carried out using confusion matrices and metrics such as accuracy, precision, recall, and *F1-score*. As an expected result, this study seeks to quantitatively demonstrate that integrating infrastructure metrics (network and battery) with sensor data optimizes the classification of disaster phases. With this study, it is expected to demonstrate that simulation combined with machine learning constitutes a promising approach to mitigate the scarcity of real *datasets* with systemic failures, providing support for the development of resilient environments for risk prediction and mitigation.

Keywords: Internet of Things. Machine Learning. Event Simulation. Disaster Prediction. IoTEventSim.

Lista de tabelas

Tabela 1 – Comparativo das características dos principais trabalhos relacionados. . 24

Lista de siglas

CDNN *Convolutional Deep Neural Networks*

CoAP *Constrained Application Protocol*

CSV *Comma-Separated Values*

FACOM Faculdade de Computação

GPAI *General-Purpose Artificial Intelligence*

IA Inteligência Artificial

IoT *Internet of Things*

KNN *K-Nearest Neighbors*

ML *Machine Learning*

MQTT *Message Queuing Telemetry Transport*

RNAs Redes Neurais Artificiais

SBRC Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos

SVM *Support Vector Machines*

TCC Trabalho de Conclusão de Curso

UFU Universidade Federal de Uberlândia

WTF Workshop de Testes e Tolerância a Falhas

Sumário

1 INTRODUÇÃO 11
1.1 Motivação 11
1.2 Problema 12
1.3 Hipótese 12
1.4 Objetivos 12
1.4.1 Objetivo Geral 12
1.4.2 Objetivos Específicos 13
1.5 Contribuições 13
1.6 Organização da Monografia 14

2 FUNDAMENTAÇÃO TEÓRICA 15
2.1 Internet das Coisas (IoT) e Arquiteturas Distribuídas 15
2.2 Cenários de Desastre e Simulação em IoT 16
2.3 Aprendizado de Máquina Supervisionado 17
2.4 Algoritmos de Classificação 18
2.5 Medidas de Avaliação de Desempenho 19
2.5.1 Acurácia 20
2.5.2 Especificidade 20
2.5.3 Sensibilidade ou Revocação 21
2.5.4 Precisão 21
2.5.5 *Fscore* 21
2.6 Trabalhos Relacionados 21

3 EXPERIMENTOS E ANÁLISE DOS RESULTADOS 26
3.1 Método para a Avaliação 26
3.1.1 Bases de Dados e Ferramentas 26
3.1.2 Conjunto de Parâmetros e Etapas 27
3.1.3 Medidas de Avaliação e Formas de Comparação 27

4 CONCLUSÃO 29
4.1 Expectativas sobre a sequência do trabalho 30

REFERÊNCIAS 31

Capítulo 1

Introdução

A aplicação de Inteligência Artificial (IA) tem se mostrado uma ferramenta indispensável no gerenciamento de crises frente ao aumento global de desastres naturais (WIBOWO et al., 2025). Essa tecnologia viabiliza o processamento ágil de dados para otimizar tanto a previsão quanto o suporte humanitário, além de permitir que modelos preditivos baseados em aprendizado de máquina identifiquem sinais precursores de catástrofes de maneira precisa, viabilizando ações proativas por parte das equipes de defesa civil (JAIN et al., 2023; ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024). Ademais, o uso dessas soluções estende-se ao período pós-desastre, acelerando a mensuração e a avaliação dos danos estruturais causados (WIBOWO et al., 2025). Nesse contexto, as métricas e anomalias de funcionamento da própria infraestrutura de dispositivos de Internet das Coisas (IoT) – como flutuações na latência de rede e picos súbitos de consumo de energia – tornam-se indicadores cruciais para mapear o status situacional do ambiente.

1.1 Motivação

A relevância desta pesquisa evidencia-se na necessidade de mitigar os impactos das catástrofes, uma vez que a detecção precoce de ocorrências extremas é crucial para uma gestão eficaz de desastres (ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024). Modelos de aprendizado de máquina exercem uma influência revolucionária nesse cenário, pois viabilizam a emissão de alertas antecipados e a alocação eficiente de recursos, salvando vidas e reduzindo perdas socioeconômicas (JAIN et al., 2023).

A literatura recente evidencia como a integração de redes IoT, *big data* e sistemas de detecção de anomalias é fundamental para o monitoramento contínuo (ANBARASAN et al., 2020; WIBOWO et al., 2025; JERIBI, 2026). Trabalhos focados na resiliência de infraestruturas indicam que a aplicação de redes neurais e aprendizado de máquina apresenta bons resultados preditivos (WONG et al., 2022; RONG et al., 2025; BURDETT; ALHAMID; KAREGAR, 2025). Nesse sentido, a motivação central deste trabalho encontra-se na união destas abordagens: contornar a escassez de dados do mundo físico através da

simulação controlada, promovendo respostas otimizadas para a recuperação de sistemas críticos.

1.2 Problema

A avaliação de sistemas IoT projetados para atuar em situações de desastre em ambientes de implantação reais é frequentemente impraticável. Tal dificuldade deve-se ao alto custo, à complexidade operacional e à limitação de reprodutibilidade em testes que envolvem condições adversas e destrutivas, como falhas severas e instabilidades de rede (COELHO et al., 2026).

Diante da severa dificuldade de obtenção de dados reais sobre falhas de infraestrutura durante esses eventos extremos, cria-se uma lacuna no treinamento de sistemas inteligentes. O problema que esta pesquisa se propõe a resolver consiste justamente em encontrar meios de avaliar a resiliência dessas redes sem depender de testes físicos, respondendo ao desafio de gerar informações confiáveis que embasem os algoritmos preditivos responsáveis pela emissão de alertas críticos.

1.3 Hipótese

A hipótese que rege esta pesquisa é a de que o uso de abordagens de simulação orientada a eventos torna-se essencial e suficiente para validar suposições e executar testes de estresse de forma controlada (COELHO et al., 2026). Pressupõe-se que, ao utilizar o IoTEventSim – um simulador orientado a eventos desenvolvido especificamente para modelar o comportamento dinâmico de aplicações de larga escala em arquiteturas de rede distribuídas *cloud-fog-edge* (estruturas que dividem o processamento entre a nuvem, a rede intermediária e a borda próxima ao usuário) (COELHO et al., 2026) – para criar cenários sintéticos controlados e extrair medições de rede e consumo de bateria, os dados gerados possuirão fidelidade suficiente para treinar, de forma eficaz, algoritmos de aprendizado de máquina. Consequentemente, postula-se que esses modelos treinados sinteticamente serão capazes de apoiar com precisão a predição e a classificação de situações críticas (fases de desastre) em ambientes IoT.

1.4 Objetivos

1.4.1 Objetivo Geral

Este trabalho tem como objetivo geral desenvolver um estudo experimental usando o simulador IoTEventSim (COELHO et al., 2026) para a modelagem e geração de cenários de desastre em ecossistemas IoT. A pesquisa visa a produção de *datasets* rotulados e a

subsequente avaliação de modelos de Aprendizado de Máquina voltados à identificação e predição das situações associadas a desastres (pré-desastre, durante o desastre e pós-desastre).

1.4.2 Objetivos Específicos

Para que o objetivo geral seja alcançado, foram definidos os seguintes objetivos específicos:

- ❏ Documentar o uso do simulador IoTEventSim (COELHO et al., 2026);
- ❏ Criar cenários simulados representando situações normais e as diversas fases do desastre em arquiteturas *cloud-fog-edge* (COELHO et al., 2026);
- ❏ Gerar conjuntos de dados a partir das simulações, extraindo medições de desempenho da rede e o estado energético dos dispositivos;
- ❏ Implementar um *pipeline* para organizar, limpar e rotular os dados gerados utilizando o ambiente *Jupyter Notebook* (Project Jupyter, 2026) e ferramentas consolidadas de Ciência de Dados em Python, como *pandas* (The pandas development team, 2026), *numpy* (NumPy Developers, 2026) e *scikit-learn* (scikit-learn developers, 2026);
- ❏ Treinar diferentes modelos de classificação em aprendizado de máquina, destacando-se Árvore de Decisão, *Random Forest*, Regressão Logística e *K-Nearest Neighbors* (KNN) (JAMES et al., 2021; SOOFI; AWAN, 2017), com os dados produzidos;
- ❏ Avaliar o desempenho dos modelos por meio de métricas estatísticas de classificação e predição (SOKOLOVA; LAPALME, 2009).

1.5 Contribuições

As principais contribuições pretendidas englobam:

- ❏ Proposição de uma abordagem robusta para mitigar a escassez histórica de dados reais de falhas em ambientes de crise através da geração de dados sintéticos fidedignos;
- ❏ Disponibilização de *datasets* rotulados que correlacionam o estado de degradação da rede e das baterias com as fases de um desastre natural;
- ❏ Produção de evidências empíricas sobre a viabilidade e a efetividade de diferentes classificadores supervisionados no monitoramento e predição de estados críticos em arquiteturas IoT (*cloud-fog-edge*).

1.6 Organização da Monografia

A organização deste trabalho está estruturada da seguinte forma:

- **Capítulo 1:** introduz o contexto da pesquisa, apresentando a motivação, o problema a ser resolvido, a hipótese levantada, os objetivos geral e específicos, as contribuições esperadas e a organização deste documento.
- **Capítulo 2:** apresenta a fundamentação teórica, contemplando os conceitos de Internet das Coisas (IoT) e arquiteturas distribuídas, simulação de cenários de desastre, aprendizado de máquina supervisionado, algoritmos de classificação e medidas de avaliação de desempenho, além da discussão dos trabalhos relacionados.
- **Capítulo 3:** aborda os experimentos e a análise dos resultados, descrevendo detalhadamente o método para a avaliação, as bases de dados e ferramentas utilizadas (como o simulador IoTEventSim), o conjunto de parâmetros e etapas, e as formas de comparação.
- **Capítulo 4:** apresenta a conclusão, contendo o relatório descritivo sobre os passos seguidos na montagem deste projeto e as expectativas sobre a sequência do trabalho prático que será executado no TCC 2.

Capítulo 2

Fundamentação Teórica

2.1 Internet das Coisas (IoT) e Arquiteturas Distribuídas

A Internet das Coisas (IoT) consiste em um paradigma tecnológico que reconfigura as relações entre os objetos físicos e o ambiente digital, estabelecendo uma rede que integra dispositivos, sistemas e serviços (FABRI et al., 2025). Este ecossistema é formado por objetos dotados de sensores, atuadores e interfaces de comunicação que coletam, transmitem e processam dados de maneira autônoma (FABRI et al., 2025). Para lidar com a escala massiva de dados e atender a requisitos de latência, as aplicações IoT frequentemente utilizam arquiteturas distribuídas no modelo nuvem-névoa-borda (cloud-fog-edge) (COELHO et al., 2026). Essa arquitetura permite que os processos operem de forma distribuída desde nós mais próximos aos sensores (borda) até a nuvem, suprindo restrições de largura de banda enquanto se beneficia da escalabilidade dos recursos da nuvem (COELHO et al., 2026).

Historicamente, a coleta de informações sobre infraestruturas (como nos casos de gestão e recuperação de desastres) dependia de metodologias de avaliação manuais, como fotografias e entrevistas, o que tornava a obtenção de dados aplicáveis um processo lento e ineficiente (BURDETT; AL-HAMID; KAREGAR, 2025). Contudo, a progressiva miniaturização dos componentes eletrônicos e a redução substancial nos custos de produção de sensores alavancaram a expansão exponencial da IoT (FABRI et al., 2025). Com o tempo, as tecnologias avançaram das antigas coletas manuais isoladas para o uso de sistemas conectados de sensores de baixo custo capazes de cobrir grandes extensões geográficas, permitindo o surgimento de ecossistemas complexos de processamento distribuído (BURDETT; AL-HAMID; KAREGAR, 2025; FABRI et al., 2025).

Entre os avanços recentes mais significativos da área, destaca-se a convergência das tecnologias IoT com a computação em nuvem, tecnologias de comunicação 5G e inteligência artificial (FABRI et al., 2025). Observa-se a emergência da computação de borda

(edge computing) como solução arquitetural fundamental para contornar problemas operacionais de latência e sobrecarga das redes de comunicação (FABRI et al., 2025). Outro avanço estrutural é a consolidação de protocolos de rede nativos voltados para dispositivos com limitações de energia e processamento, como os protocolos Constrained Application Protocol (CoAP) (baseado em requisição-resposta) e Message Queuing Telemetry Transport (MQTT) (baseado em publicação-assinatura) (COELHO et al., 2026). Há também o desenvolvimento de frameworks que integram essas vastas redes IoT de arquitetura distribuída com modelos de aprendizado de máquina para prever falhas de infraestrutura e otimizar ações de resposta (BURDETT; AL-HAMID; KAREGAR, 2025).

Um exemplo relevante da utilização da IoT em arquiteturas distribuídas é a implementação das Cidades Inteligentes, onde soluções descentralizadas monitoram a mobilidade urbana, a eficiência energética e a segurança pública (FABRI et al., 2025). Outro exemplo crítico é o uso de redes IoT na recuperação pós-desastre (como terremotos); neste cenário, sensores incorporados na rede elétrica monitoram a passagem de energia e permitem identificar instantaneamente cabos rompidos, priorizando os reparos com auxílio de sistemas centralizados de inteligência artificial (BURDETT; AL-HAMID; KAREGAR, 2025). Por fim, um exemplo do campo de testes em IoT são simuladores distribuídos, como o IoTEventSim, que permitem emular eventos dinâmicos (como queda de pacotes e falhas de bateria) em milhares de dispositivos em um ambiente cloud-fog-edge, possibilitando estudos controlados antes da implementação real (COELHO et al., 2026).

2.2 Cenários de Desastre e Simulação em IoT

Cenários de desastre referem-se a situações de crise crônicas ou agudas, como terremotos, tempestades severas ou falhas em infraestruturas críticas, onde a rápida obtenção de dados é essencial para mitigar perdas humanas e econômicas. No contexto da Internet das Coisas, a gestão de desastres envolve o uso de redes de sensores distribuídos para monitorar o ambiente. Como testar esses ecossistemas hiperconectados em ambientes reais durante um desastre é caro, operacionalmente complexo e de difícil reprodução (COELHO et al., 2026), a simulação torna-se uma abordagem mandatória. A simulação em IoT consiste na modelagem computacional do comportamento de dispositivos, redes e condições físicas para replicar cenários dinâmicos (como quedas de conectividade ou falhas de bateria) e validar estratégias de resposta de forma controlada (COELHO et al., 2026).

Historicamente, a avaliação de danos e o planejamento de resposta a desastres dependiam quase exclusivamente de métodos de coleta manuais, como fotografias, entrevistas, relatórios financeiros e inspeções visuais pós-evento, resultando em grandes atrasos na tomada de decisão (BURDETT; AL-HAMID; KAREGAR, 2025). Com a consolidação das redes de sensores, a resposta a desastres começou a transitar para o monitoramento proativo. Inicialmente, os simuladores de IoT focavam apenas na infraestrutura de rede

abstrata, falhando em capturar a dinâmica individual dos sensores, como esgotamento de energia e mobilidade (COELHO et al., 2026). Essa limitação impulsionou o desenvolvimento de simuladores orientados a eventos, capazes de modelar interrupções transitórias de forma escalável, preservando o controle granular sobre cada dispositivo no cenário simulado (COELHO et al., 2026).

Os avanços mais recentes na área demonstram uma forte integração entre simuladores IoT e modelos preditivos baseados em Inteligência Artificial (IA) e Aprendizado de Máquina (ML). Revisões bibliométricas atuais destacam uma mudança massiva de paradigma: a IA deixou de ser apenas uma ferramenta de análise para se tornar o núcleo da preparação, mitigação e resposta a desastres (WIBOWO et al., 2025). Na prática, plataformas modernas de simulação permitem a injeção de eventos em tempo de execução em arquiteturas distribuídas para emular falhas dinâmicas e treinar algoritmos preditivos (COELHO et al., 2026). Paralelamente, algoritmos de ML estão sendo ativamente alimentados com dados simulados e leituras de sensores ambientais para prever padrões climáticos e desastres naturais com precisão inédita (JAIN et al., 2023), acelerando drasticamente o direcionamento de equipes de resgate (BURDETT; AL-HAMID; KAREGAR, 2025).

Um exemplo proeminente dessa tecnologia é o simulador IoTEventSim, que permite testar a robustez de arquiteturas IoT reproduzindo eventos adversos, como perda de pacotes de rede e falhas permanentes de energia em milhares de dispositivos simultaneamente, sem a necessidade de testes físicos destrutivos (COELHO et al., 2026). Outro exemplo prático é a aplicação conjunta de simulação e Machine Learning para a recuperação de infraestruturas pós-terremoto: pesquisadores criam mapas digitais da rede elétrica (como modelado para Christchurch, na Nova Zelândia) e simulam danos causados pela liquefação do solo; esses dados simulados treinam algoritmos para identificar instantaneamente os "nós"(cruzamentos de cabos e subestações) de maior risco e criticidade (BURDETT; AL-HAMID; KAREGAR, 2025). Esses mesmos princípios estão sendo extrapolados para modelos de previsão meteorológica, onde redes neurais avaliam dados de sensores para emitir alertas precoces de desastres naturais (JAIN et al., 2023).

2.3 Aprendizado de Máquina Supervisionado

O Aprendizado de Máquina investiga técnicas que permitem a aquisição automática de conhecimento a partir de dados. Suas abordagens dividem-se fundamentalmente em tarefas descritivas (focadas na exploração e descoberta de padrões, como o agrupamento) e tarefas preditivas. As tarefas preditivas induzem um modelo matemático capaz de predizer um atributo-alvo com base na presença de um "supervisor externo"— ou seja, um conjunto de dados onde a resposta correta já é conhecida previamente (aprendizado supervisionado). Quando o atributo-alvo dessa predição é discreto, trata-se de uma tarefa

de classificação; quando contínuo, de uma regressão (FACELI et al., 2025).

Nos anos 1970, a Inteligência Artificial focava no desenvolvimento de Sistemas Especialistas, que tentavam codificar o conhecimento humano por meio de regras lógicas rigorosas. Contudo, a dificuldade de extrair essas informações e a recente proliferação de dispositivos capazes de gerar grandes volumes de dados fizeram com que o Aprendizado de Máquina superasse os modelos baseados em regras, tornando-se a subárea mais proeminente da IA (FACELI et al., 2025).

O avanço da capacidade computacional permitiu o treinamento de Redes Neurais Artificiais (RNAs) profundas, que alcançaram desempenhos estado-da-arte em áreas complexas como visão computacional e processamento de linguagem natural. Adicionalmente, o surgimento das Inteligências Artificiais de Propósito Geral (GPAI), fundamentadas em foundation models, popularizou a IA generativa, demonstrando alta capacidade de adaptação em múltiplos domínios (FACELI et al., 2025).

Um exemplo prático do aprendizado supervisionado preditivo no contexto de desastres é o desenvolvimento de sistemas para detectar inundações utilizando IoT e Big Data. Em abordagens recentes, classificadores baseados em Redes Neurais Convolucionais Profundas (CDNN) são treinados utilizando dados massivos coletados por sensores ambientais . O algoritmo recebe como entrada dados provenientes de sensores de fluxo de água, nível de água, precipitação e umidade. Após um processo que combina esses atributos, o modelo classificador aprende os padrões e consegue classificar o cenário alvo em duas categorias discretas: com chances de ocorrência de enchente ou sem chances de ocorrência de enchente (ANBARASAN et al., 2020)

2.4 Algoritmos de Classificação

A classificação é uma técnica de aprendizado de máquina e mineração de dados cujo objetivo principal é prever a filiação de instâncias de dados a grupos ou categorias discretas predefinidas (SOOFI; AWAN, 2017). Diferente dos modelos de regressão linear clássica, que assumem uma variável de resposta quantitativa e contínua, os algoritmos classificadores são projetados especificamente para lidar com respostas qualitativas ou categóricas (JAMES et al., 2021). Na prática, muitas dessas técnicas funcionam estimando primeiramente a probabilidade de uma observação pertencer a cada uma das categorias possíveis, utilizando essa métrica como alicerce matemático para realizar a classificação definitiva (JAMES et al., 2021).

Tradicionalmente, a identificação e a categorização de fenômenos complexos na natureza dependiam de abordagens clássicas baseadas em observação humana direta, relatórios manuais, sismologia ou leituras isoladas de radares e sensores (ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024). Com a expansão do volume de dados e da capacidade computacional, modelos estatísticos multivariados (como a regressão logística e o

K-nearest neighbors) e algoritmos indutivos baseados em árvores de decisão ganharam protagonismo para automatizar a extração dessas fronteiras de decisão (JAMES et al., 2021; SOOFI; AWAN, 2017).

Entre os algoritmos de classificação amplamente utilizados na literatura, destacam-se a regressão logística, que atua modelando diretamente a probabilidade de uma observação pertencer a uma categoria específica, e o algoritmo KNN (K-Nearest Neighbors), uma abordagem que atribui um novo dado à classe mais frequente entre os seus K vizinhos mais próximos no conjunto de treinamento. No escopo dos métodos de aprendizado baseados em árvores, sobressaem-se as árvores de decisão, que operam estratificando e segmentando o espaço de variáveis preditoras em regiões menores e interpretáveis. Para contornar a alta variância das árvores individuais, emprega-se o Random Forest, um método que constrói um grande número de árvores de decisão não correlacionadas entre si, resultando em um ganho de precisão preditiva. Por fim, as Máquinas de Vetores de Suporte (SVM) são projetadas para encontrar um hiperplano de separação ótimo que maximize a margem geométrica entre diferentes classes (JAMES et al., 2021).

Os avanços contemporâneos mais expressivos envolvem o emprego de redes profundas (Deep Learning) e o desenvolvimento de arquiteturas descentralizadas, como o aprendizado federado (federated learning) integrado a ambientes de computação de borda móvel (mobile edge computing) (WONG et al., 2022). Essas inovações permitem o processamento massivo e a classificação de dados de forma distribuída, mitigando limitações severas de latência, largura de banda e privacidade em redes de grande escala (WONG et al., 2022). Adicionalmente, a literatura recente destaca a convergência e hibridização de múltiplos classificadores para incrementar a precisão e a eficiência na detecção automática de anomalias em tempo real (ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024).

Um exemplo prático de alto impacto é a aplicação de algoritmos de classificação no gerenciamento eficaz de desastres naturais, como terremotos, inundações, incêndios florestais e furacões (ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024). Modelos de classificação otimizados são implementados em redes sem fio e ecossistemas conectados para realizar a categorização automática da severidade de eventos críticos e a detecção de vítimas em tempo real (WONG et al., 2022). Nesses ambientes, os algoritmos processam as métricas coletadas para rotular o status do cenário operacional, fornecendo subsídios rápidos que aceleram a tomada de decisão e otimizam o direcionamento de equipes de suporte humanitário (ABRAHAM; ABDELWAHAB; ABO-ZAHHAD, 2024; WONG et al., 2022).

2.5 Medidas de Avaliação de Desempenho

A avaliação do desempenho de modelos preditivos é um requisito essencial para mensurar a qualidade, a confiabilidade e a capacidade de generalização de algoritmos de

aprendizado de máquina em diferentes domínios de aplicação. As medidas de desempenho fornecem o fundamento formal para determinar o que constitui um comportamento classificador aceitável ou ótimo diante de um problema prático (SOKOLOVA; LAPALME, 2009).

Historicamente, o estudo e a aplicação de sistemas de classificação concentravam-se majoritariamente em problemas binários, nos quais os objetos do mundo real são mapeados em apenas duas categorias mutuamente exclusivas (geralmente rotuladas como positivas ou negativas). Com a evolução da área e a necessidade de solucionar problemas de maior complexidade, as tarefas de classificação expandiram-se para estruturas computacionais diversas, incluindo problemas multiclasse (múltiplas categorias excludentes), problemas multirrótulo (onde uma mesma instância pode pertencer a várias classes simultaneamente) e classificações hierárquicas organizadas em árvores ou grafos direcionados (SOKOLOVA; LAPALME, 2009).

Dentre os principais avanços e discussões contemporâneas na área, destaca-se a análise sistemática de como as propriedades dos dados afetados por desbalanceamento de classes, variações no volume amostral e mudanças na prevalência de rótulos impactam diretamente a confiabilidade das métricas clássicas . Pesquisas recentes concentram-se no estudo da invariância das medidas de desempenho, buscando compreender quais métricas permanecem estáveis e quais são severamente distorcidas quando ocorrem alterações na distribuição populacional dos dados reais (SOKOLOVA; LAPALME, 2009).

2.5.1 Acurácia

A acurácia avalia a efetividade geral de um classificador (SOKOLOVA; LAPALME, 2009). Ela calcula a proporção de predições corretas (tanto positivas quanto negativas) em relação ao total de instâncias avaliadas.

$$\text{Acurácia} = \frac{TP + TN}{TP + FP + FN + TN} \tag{1}$$

Onde TP é o número de Verdadeiros Positivos, TN é o número de Verdadeiros Negativos, FP é o número de Falsos Positivos e FN é o número de Falsos Negativos.

2.5.2 Especificidade

A especificidade mede quão efetivamente um classificador identifica os rótulos negativos (SOKOLOVA; LAPALME, 2009).

$$\text{Especificidade} = \frac{TN}{TN + FP} \tag{2}$$

Onde TN é o número de Verdadeiros Negativos (casos negativos classificados corretamente) e FP é o número de Falsos Positivos (casos negativos classificados incorretamente como positivos).

2.5.3 Sensibilidade ou Revocação

A sensibilidade (também referida como revocação) avalia a efetividade de um classificador em identificar rótulos positivos (SOKOLOVA; LAPALME, 2009).

$$\text{Sensibilidade} = \text{Revocação} = \frac{TP}{TP + FN} \tag{3}$$

Onde TP é o número de Verdadeiros Positivos (casos positivos classificados corretamente) e FN é o número de Falsos Negativos (casos positivos classificados incorretamente como negativos).

2.5.4 Precisão

A precisão mede a concordância de classe entre os rótulos reais dos dados e os rótulos positivos atribuídos pelo classificador (SOKOLOVA; LAPALME, 2009).

$$\text{Precisão} = \frac{TP}{TP + FP} \tag{4}$$

Onde TP é o número de Verdadeiros Positivos (casos positivos identificados corretamente) e FP é o número de Falsos Positivos (casos negativos identificados incorretamente como positivos).

2.5.5 *Fscore*

A métrica *Fscore* avalia a relação entre os rótulos positivos reais presentes nos dados e aqueles fornecidos por um classificador (SOKOLOVA; LAPALME, 2009). Na sua forma harmônica tradicional, ela é expressa matematicamente como:

$$Fscore = 2 \times \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \tag{5}$$

Onde Precisão e Revocação correspondem aos resultados previamente calculados por suas respectivas fórmulas, equilibrando o peso dos falsos positivos e falsos negativos na avaliação.

2.6 Trabalhos Relacionados

A seleção dos trabalhos que compõem o referencial teórico desta pesquisa apoiou-se em um mapeamento da literatura recente, priorizando publicações entre 2020 e 2026 em bases acadêmicas e periódicos de relevância nas áreas de Ciência da Computação e Engenharias. A estratégia de levantamento bibliográfico foi estruturada em torno dos três eixos fundamentais que norteiam este projeto: a aplicação de modelos de Inteligência Artificial para predição e monitoramento de desastres, o comportamento de infraestruturas IoT em arquiteturas *cloud-fog-edge* e o uso de simulação para a geração de dados sintéticos.

Por meio de uma triagem focada no alinhamento tecnológico e metodológico, foram selecionados os estudos que representam o estado da arte na integração dessas áreas. Paralelamente à revisão de literatura, conduziu-se uma varredura exploratória em repositórios abertos de dados para validar a lacuna de pesquisa abordada neste estudo. Esse processo confirmou a escassez de *datasets* públicos que correlacionem o impacto físico de catástrofes naturais à degradação de métricas de rede – como latência, perda de pacotes e consumo energético –, uma vez que as bases existentes costumam se limitar a variáveis puramente meteorológicas ou ao contexto exclusivo de cibersegurança. Diante desse cenário, os trabalhos de maior impacto e proximidade com a proposta deste estudo são detalhados a seguir.

O uso de algoritmos de aprendizado de máquina tem se mostrado essencial para prever padrões climáticos e mitigar os impactos de desastres naturais, como furacões e inundações. O trabalho de Jain et al. (2023) objetiva explorar a influência de algoritmos de aprendizado de máquina na preparação e resposta a catástrofes. A partir de uma revisão da literatura sobre análise de dados complexos, os resultados demonstram a eficácia de modelos preditivos na antecipação de fenômenos meteorológicos extremos, permitindo a implementação de ações preventivas que salvam vidas. Este estudo fornece subsídios para a proposta deste Trabalho de Conclusão de Curso (TCC) ao demonstrar a viabilidade do uso de algoritmos supervisionados, como o *Random Forest*, para predizer estados críticos, método que será replicado no presente projeto para classificar as diferentes fases de um desastre (normal, pré-desastre, desastre e pós-desastre) a partir de dados multivariados. A pesquisa apresenta elevada relevância na literatura, sendo veiculada no periódico internacional *Frontiers in Environmental Science*, avaliado com o estrato Qualis A3.

Aprofundando a classificação rápida e a detecção visual desses eventos, Abraham, Abdelwahab e Abo-Zahhad (2024) realizaram uma revisão sobre o uso de técnicas clássicas e de *Deep Learning* para o gerenciamento de crises. O estudo avalia os benefícios e as limitações de abordagens tecnológicas (como imagens de satélite e radar) para identificar desastres naturais. Como resultado principal, os autores enfatizam que os avanços atuais em redes neurais aumentam significativamente a precisão e a eficiência na detecção e categorização de anomalias. Os resultados servem de base para a pesquisa atual ao validar a importância da categorização preditiva de situações de risco, corroborando o objetivo do projeto em implementar um *pipeline* de aprendizado de máquina focado em métricas de rede e de sensores para classificar a severidade do cenário operacional. O artigo foi publicado na revista *Earth Science Informatics*, periódico que detém estrato Qualis A3, atestando seu rigor científico em áreas como Computação e Geociências.

Para lidar com anomalias de dados e otimizar redes em tempo real, Kaya et al. (2023) propuseram uma abordagem inteligente de detecção de anomalias meteorológicas na borda da Internet das Coisas (*IoT edges*). A metodologia testou cinco algoritmos de aprendizado de máquina (incluindo *Naive Bayes* e *Random Forest*) para processar e filtrar dados

com precisão e confiabilidade, removendo informações ausentes ou desnecessárias geradas por sensores. Os resultados revelam os diferentes níveis de precisão dos algoritmos no tratamento dos dados da detecção climática em ambientes IoT. A metodologia proposta inspira de forma direta o nosso projeto ao validar uma avaliação comparativa entre múltiplos algoritmos de classificação em dados gerados na borda, fundamentando a etapa de experimentação deste TCC, que testará modelos como Árvore de Decisão, *Random Forest*, Regressão Logística e KNN sobre dados simulados. O estudo consolida sua contribuição científica ao ser publicado na revista *Sensors*, periódico reconhecido e classificado no estrato Qualis A4 para as áreas de Computação e Engenharias.

A avaliação e validação de infraestruturas IoT complexas demandam ferramentas específicas de teste. Nesse sentido, Coelho et al. (2026) desenvolveram o IoTEventSim, um simulador orientado a eventos voltado para aplicações em larga escala nas arquiteturas *Cloud-Fog-Edge*. O método modela cada dispositivo como uma entidade autônoma, lidando com protocolos como MQTT e eventos que modificam o comportamento da rede ao longo do tempo. Os testes práticos indicaram que a ferramenta consegue reproduzir, com relatada alta fidelidade, características de latência e perda de pacotes, escalando para milhares de dispositivos simultâneos. Diferentemente das abordagens estritamente teóricas, este artigo fundamenta a arquitetura metodológica do nosso projeto, visto que o simulador IoTEventSim será a ferramenta base empregada para gerar os cenários sintéticos de desastre, emular a degradação da rede e da bateria, e extrair os conjuntos de dados tabulares essenciais para o treinamento dos modelos preditivos, suprindo a escassez de dados reais de falhas. Trata-se de uma importante referência nacional apresentada no Workshop de Testes e Tolerância a Falhas (WTF), evento satélite do Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC), fórum de destaque da área no país, avaliado com o conceito Qualis A4.

Por fim, para compreender o panorama acadêmico dessas soluções tecnológicas, Wibowo et al. (2025) conduziram uma revisão bibliométrica abrangente sobre a aplicação de inteligência artificial na gestão de desastres. A metodologia consistiu na análise de 848 publicações extraídas da base Scopus, utilizando mapeamento de redes. Os principais resultados revelaram um rápido crescimento (15,6% ao ano) na área e agruparam a pesquisa em vertentes como monitoramento IoT e tecnologias geoespaciais baseadas em IA. A pesquisa complementa o referencial teórico do presente trabalho ao evidenciar a alta relevância da integração entre monitoramento de redes IoT distribuídas e classificação via IA para a gestão e mitigação de riscos. O impacto da pesquisa ancora-se na sua publicação no *Jambá: Journal of Disaster Risk Studies*, periódico com expressiva excelência acadêmica evidenciada pela sua classificação Qualis A2.

Em síntese, os trabalhos analisados evidenciam o expressivo potencial da inteligência artificial e da borda computacional (*Edge Computing*) para a detecção de anomalias meteorológicas e gestão de desastres, seja via redes de sensores reais ou análises geoes-

paciais e bibliométricas. Contudo, nota-se na literatura uma carência de abordagens que estruturem *pipelines* preditivos a partir da degradação das próprias redes de comunicação (Cloud-Fog-Edge) durante o evento extremo. O levantamento supracitado comprovou a inexistência de conjuntos de dados abertos que relacionem métricas operacionais de rede com cenários de desastres. Em contraste com os trabalhos que dependem exclusivamente de dados climáticos já consolidados, o presente TCC busca preencher essa lacuna ao adotar uma simulação de eventos acoplada à IA. Tal estratégia possibilita a geração e a extração dessas métricas de rede em cenários de desastre, viabilizando uma classificação precisa e antecipada da severidade de desastres e contornando, assim, a escassez prática de *datasets* focados em infraestruturas falhas.

Tabela 1 – Comparativo das características dos principais trabalhos relacionados.

Trabalho	**Objetivo Principal**	**Método e Tecnologias**	**Principais Resultados**
Leveraging Artificial Intelligence for Extreme Weather Prediction Jain et al. (2023)	Explorar o uso de inteligência artificial na previsão de eventos meteorológicos extremos.	Revisão da aplicação de modelos supervisionados de *Machine Learning*, como *Random Forest*, para análise de dados meteorológicos.	Elevada capacidade preditiva, contribuindo para a antecipação de desastres e o apoio à tomada de decisões.
Classification of Natural Disasters: A Review Abraham, Abdelwahab e Abo-Zahhad (2024)	Revisar técnicas de detecção e classificação de desastres naturais.	Análise de abordagens baseadas em *Deep Learning* e inteligência artificial tradicional aplicadas ao processamento de dados provenientes de sensores.	Melhoria da precisão na classificação de eventos por meio de modelos preditivos mais avançados.
An Intelligent IoT-Based Weather Forecasting System Using Edge Computing Kaya et al. (2023)	Aumentar a precisão das previsões meteorológicas em redes IoT.	Processamento em *edge computing* com avaliação de cinco algoritmos classificadores.	Comparação entre algoritmos, evidenciando o equilíbrio entre precisão e custo computacional.

Trabalho	**Objetivo Principal**	**Método e Tecnologias**	**Principais Resultados**
IoTEventSim: An IoT Event Simulator for Cloud-Fog-Edge Environments Coelho et al. (2026)	Avaliar aplicações IoT em arquiteturas *Cloud-Fog-Edge*.	Utilização do simulador *IoTEventSim* para modelagem de dispositivos e simulação de falhas de rede.	Simulação realista da latência e geração de parâmetros dinâmicos em larga escala.
Leveraging Artificial Intelligence for Disaster Management: A Bibliometric Review Wibowo et al. (2025)	Identificar tendências de pesquisa sobre inteligência artificial aplicada à gestão de desastres.	Revisão bibliométrica de publicações indexadas na base Scopus.	Evidência do crescimento da integração entre IA e IoT para mitigação de riscos e apoio à resposta a desastres.
Presente TCC	Gerar dados sintéticos de falhas em redes IoT e predizer situações críticas de desastre.	Uso do simulador *IoTEventSim* integrado a classificadores supervisionados (*Random Forest*, KNN, Regressão Logística).	Avaliação do desempenho de modelos preditivos na classificação das fases de um desastre utilizando dados simulados.

Capítulo 3

Experimentos e Análise dos Resultados

Este capítulo detalha a metodologia experimental proposta para validar a hipótese deste trabalho. A Seção 3.1 descreve os métodos que serão utilizados para a avaliação, abordando o processo de simulação, a geração das bases de dados, as métricas e os parâmetros que guiarão a execução futura dos experimentos e a análise do desempenho dos modelos preditivos diante dos cenários de desastre propostos.

3.1 Método para a Avaliação

A abordagem metodológica deste trabalho caracteriza-se como um estudo experimental voltado a suprir a escassez de dados reais de falhas em ambientes IoT. Para validar a hipótese do estudo, será estabelecido um *pipeline* estruturado que envolve a simulação de cenários de desastre, a extração de métricas de rede e bateria e a subsequente aplicação de algoritmos de aprendizado de máquina.

3.1.1 Bases de Dados e Ferramentas

Para a geração da base de dados e condução do estudo, optou-se pela utilização do IoTEventSim (COELHO et al., 2026), um simulador voltado para aplicações IoT em arquiteturas *cloud-fog-edge*. O simulador permite configurar parâmetros de dispositivos individuais (como localização, bateria, latência, perda de pacotes e leituras de sensores), viabilizando a injeção de eventos transitórios ou permanentes para emular os cenários de desastre.

Como produto dessa simulação, serão gerados conjuntos de dados sintéticos estruturados em formato Comma-Separated Values (CSV). Esses *datasets* tabulares associarão as métricas operacionais coletadas a rótulos de classes correspondentes ao status da infraestrutura (normal, pré-desastre, desastre e pós-desastre). Toda a manipulação, organização e modelagem dos dados será desenvolvida em linguagem Python, com o apoio de bibliotecas como *pandas*, *numpy*, *matplotlib* e *scikit-learn*.

3.1.2 Conjunto de Parâmetros e Etapas

O núcleo experimental focará na aplicação de algoritmos de classificação supervisionada sobre a base gerada. O trabalho avaliará o desempenho preditivo de modelos clássicos da literatura, como Árvore de Decisão, *Random Forest*, Regressão Logística e KNN.

O processo experimental seguirá uma sequência metodológica rigorosa: configuração do simulador; definição dos cenários de desastre e mapeamento das flutuações de parâmetros; geração e rotulação dos dados sintéticos; pré-processamento para balanceamento e tratamento de valores; e, por fim, o treinamento dos classificadores. Visando garantir a transparência da avaliação, todo o código-fonte e os *datasets* gerados comporão um repositório público documentado (ex: GitHub).

3.1.3 Medidas de Avaliação e Formas de Comparação

A validação da eficácia dos modelos de aprendizado de máquina será efetuada por meio de métricas quantitativas padrão para tarefas de classificação (SOKOLOVA; LAPALME, 2009):

- **Acurácia, Precisão, Revocação (*Recall*) e *F1-score*:** Medidas utilizadas em conjunto para mensurar a taxa de acertos gerais e a capacidade do modelo em detectar corretamente as classes críticas de interesse.
- **Matriz de Confusão:** Ferramenta empregada para analisar detalhadamente os erros de classificação, identificando falsos positivos e falsos negativos na transição entre estados normais e críticos.

Para atestar a capacidade de generalização das propostas, serão aplicadas a separação entre conjuntos de treino e teste, além de técnicas de validação cruzada.

No que tange às formas de comparação, o método principal consistirá em uma avaliação analítica interna. Os classificadores terão seu desempenho contrastado sob diferentes configurações de atributos de entrada. Inicialmente, os modelos serão testados estritamente com dados de sensores ambientais. Em seguida, a proposta será comparada contra os mesmos modelos alimentados com a combinação total de métricas: sensores ambientais, degradação da rede e consumo de bateria. Essa abordagem permitirá quantificar objetivamente o ganho preditivo alcançado pela inclusão de informações oriundas da infraestrutura IoT na detecção antecipada de situações de desastre.

Declaração sobre o Uso de Inteligência Artificial

Em conformidade com as boas práticas de transparência acadêmica, declara-se o uso de Inteligência Artificial, especificamente o modelo de linguagem Gemini (Google), como

ferramenta de apoio durante a redação deste documento. A tecnologia foi empregada exclusivamente para auxiliar na revisão gramatical, no aprimoramento da clareza e fluidez textual, e como suporte técnico para a formatação do trabalho em LaTeX. Ressalta-se que a concepção teórica do projeto, a definição da metodologia e a autoria intelectual de todas as ideias aqui apresentadas são de inteira responsabilidade do autor.

Capítulo 4

Conclusão

Relatório final para descrever os passos que segui na montagem da versão final deste projeto de TCC, partindo das entregas (E1 a E4) realizadas ao longo da disciplina.

Para adequar os textos ao modelo oficial da monografia da FACOM, precisei fazer diversas adaptações e correções. O detalhamento do que eu fiz em cada seção está descrito a seguir:

- **Capítulo 1 (Introdução):** Para montar a introdução, eu utilizei o texto base da Entrega 1 (E1). Tive que adaptar o formato, dividindo o texto original nas subseções exigidas pelo *template* (Motivação, Problema, Hipótese, Objetivos e Contribuições). Além disso, corrigi o texto segundo as sugestões do professor: adicionei referências logo no primeiro parágrafo para embasar as afirmações "fortes"sobre a área e passei a colocar as siglas por extenso na primeira ocorrência.

- **Capítulo 2 (Fundamentação Teórica):** Aqui, eu juntei a teoria da Entrega 2 (E2) com a pesquisa de Trabalhos Relacionados da Entrega 3 (E3). Seguindo o *feedback* do professor, adicionei um parágrafo introdutório explicando exatamente onde e como os trabalhos foram procurados (bases utilizadas, recorte temporal e *strings* de busca) e por que eles são considerados relacionados. Tive também que remover os resumos dos capítulos do livro-texto da disciplina, pois eram apenas para a avaliação da matéria e não cabiam no formato final do TCC.

- **Capítulo 3 (Experimentos e Análise dos Resultados):** Para estruturar a metodologia, eu utilizei o que foi definido na Entrega 4 (E4). Tive que adaptar a escrita, que originalmente estava em formato de tópicos e respostas, transformando-a em um texto corrido que descreve o *pipeline* de simulação, os parâmetros e as métricas. Também transferi a declaração de uso de IA (Gemini) para esta seção, explicando que a utilizei para revisão e formatação em LaTeX.

4.1 Expectativas sobre a sequência do trabalho

Agora que o projeto está estruturado e a metodologia definida, a minha expectativa para a sequência do trabalho (TCC 2) é focar na execução prática dos experimentos. O próximo passo será configurar o simulador IoTEventSim, gerar os cenários de desastre injetando falhas na rede e na bateria, e extrair os dados. Com os *datasets* gerados, pretendo rodar os classificadores (Árvore de Decisão, *Random Forest*, Regressão Logística e KNN) para avaliar se a inclusão das métricas de infraestrutura realmente melhora a precisão na detecção das fases do desastre.

Referências

ABRAHAM, K.; ABDELWAHAB, M.; ABO-ZAHHAD, M. Classification and detection of natural disasters using machine learning and deep learning techniques: A review. **Earth Science Informatics**, v. 17, n. 2, p. 869–891, abr. 2024. ISSN 1865-0481. Disponível em: <https://doi.org/10.1007/s12145-023-01205-2>. Citado 5 vezes nas páginas 11, 18, 19, 22 e 24.

ANBARASAN, M. et al. Detection of flood disaster system based on IoT, big data and convolutional deep neural network. **Computer Communications**, v. 150, p. 150–157, 2020. Disponível em: <https://doi.org/10.1016/j.comcom.2019.11.022>. Citado 2 vezes nas páginas 11 e 18.

BURDETT, N.; AL-HAMID, D. Z.; KAREGAR, P. A. IoT and Machine Learning for Post-Earthquake Infrastructure Recovery: A New Zealand Case Study. **IEICE Proceedings Series**, v. 97, n. F3-3-4, nov. 2025. ISSN 2188-5079. Disponível em: <https://doi.org/10.34385/proc.97.F3-3-4>. Citado 4 vezes nas páginas 11, 15, 16 e 17.

COELHO, P. et al. IoTEventSim: an Event-Driven Simulator for Large-Scale IoT Applications in Cloud–Fog–Edge Architectures. In: **Workshop de Testes e Tolerância a Falhas (WTF)**. Porto Alegre: SBC, 2026. p. 122–135. ISSN 2595-2684. Disponível em: <https://doi.org/10.5753/wtf.2026.22886>. Citado 8 vezes nas páginas 12, 13, 15, 16, 17, 23, 25 e 26.

FABRI, E. V. et al. A revolução da internet das coisas (IoT): conectando o mundo físico e digital. **Revista Missioneira**, v. 27, n. 1, p. 173–183, abr. 2025. ISSN 2594-9950. Disponível em: <https://doi.org/10.31512/missioneira.v27i1.2120>. Citado 2 vezes nas páginas 15 e 16.

FACELI, K. et al. **Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina**. 3. ed. Rio de Janeiro: LTC, 2025. ISBN 978-85-216-3920-6. Citado na página 18.

JAIN, H. et al. Leveraging machine learning algorithms for improved disaster preparedness and response through accurate weather pattern and natural disaster prediction. **Frontiers in Environmental Science**, v. 11, nov. 2023. ISSN 2296-665X. Disponível em: <https://doi.org/10.3389/fenvs.2023.1194918>. Citado 4 vezes nas páginas 11, 17, 22 e 24.

JAMES, G. et al. **An Introduction to Statistical Learning: With Applications in R**. 2. ed. New York: Springer, 2021. ISBN 978-1-0716-1417-4. Citado 3 vezes nas páginas 13, 18 e 19.

JERIBI, F. Context-aware spiking neural networks for real-time anomaly detection in IOT-enabled smart energy systems. **Electric Power Systems Research**, v. 256, p. 112858, 2026. Disponível em: <https://doi.org/10.1016/j.epsr.2026.112858>. Citado na página 11.

KAYA, S. M. et al. An Intelligent Anomaly Detection Approach for Accurate and Reliable Weather Forecasting at IoT Edges: A Case Study. **Sensors**, v. 23, n. 5, p. 2426, jan. 2023. ISSN 1424-8220. Disponível em: <https://doi.org/10.3390/s23052426>. Citado 2 vezes nas páginas 22 e 24.

NumPy Developers. **NumPy**. 2026. Disponível em: <https://numpy.org/>. Acesso em: 2 ago. 2026. Citado na página 13.

Project Jupyter. **Project Jupyter**. 2026. Disponível em: <https://jupyter.org/>. Acesso em: 2 ago. 2026. Citado na página 13.

RONG, X. et al. Generative AI-Augmented Monte Carlo Simulation for Resilience Assessment of Typhoon-Affected Power Distribution Systems. **CSEE Journal of Power and Energy Systems**, v. 11, n. 6, p. 2659–2672, nov. 2025. ISSN 3066-9308. Disponível em: <https://doi.org/10.17775/CSEEJPES.2025.06160>. Citado na página 11.

scikit-learn developers. **scikit-learn: Machine Learning in Python**. 2026. Disponível em: <https://scikit-learn.org/>. Acesso em: 2 ago. 2026. Citado na página 13.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427–437, jul. 2009. ISSN 03064573. Disponível em: <https://doi.org/10.1016/j.ipm.2009.03.002>. Citado 4 vezes nas páginas 13, 20, 21 e 27.

SOOFI, A. A.; AWAN, A. Classification Techniques in Machine Learning: Applications and Issues. **Journal of Basic & Applied Sciences**, v. 13, p. 459–465, jan. 2017. ISSN 1927-5129, 1814-8085. Disponível em: <https://doi.org/10.6000/1927-5129.2017.13.76>. Citado 3 vezes nas páginas 13, 18 e 19.

The pandas development team. **pandas - Python Data Analysis Library**. 2026. Disponível em: <https://pandas.pydata.org/>. Acesso em: 2 ago. 2026. Citado na página 13.

WIBOWO, A. et al. Leveraging artificial intelligence in disaster management: A comprehensive bibliometric review. **Jàmbá: Journal of Disaster Risk Studies**, v. 17, n. 1, p. 9, abr. 2025. ISSN 1996-1421. Disponível em: <https://doi.org/10.4102/jamba.v17i1.1776>. Citado 4 vezes nas páginas 11, 17, 23 e 25.

WONG, Y. J. et al. An Optimized Multi-Task Learning Model for Disaster Classification and Victim Detection in Federated Learning Environments. **IEEE Access**, v. 10, p. 115930–115944, 2022. ISSN 2169-3536. Disponível em: <https://doi.org/10.1109/ACCESS.2022.3218655>. Citado 2 vezes nas páginas 11 e 19.